Studi Ablasi RNN, LSTM, dan GRU dibandingkan ANN untuk Prediksi Trafik Seluler Kota Milan

Isabella Silalahi
NIM 124400068
Teknik Telekomunikasi, ITERA
isabella.124400068@student.itera.ac.id

Dwi Yanti Maharani
NIM 124400084
Teknik Telekomunikasi, ITERA
dwiyanti.124400084@student.itera.ac.id

Lusitania Fachria Salsabila
NIM 123400032
Teknik Telekomunikasi, ITERA
lusitania.123400032@student.itera.ac.id

***Abstract*—Prediksi beban trafik internet seluler per jam memegang peranan krusial bagi operator telekomunikasi dalam manajemen sumber daya radio dinamis dan efisiensi energi. Studi ini menyajikan investigasi empiris komprehensif melalui studi ablasi sistematis untuk membandingkan empat arsitektur: Artificial Neural Network (ANN), Recurrent Neural Network (RNN), Long Short-Term Memory (LSTM), dan Gated Recurrent Unit (GRU), menggunakan dataset Telecom Italia pada kawasan Duomo (kotak 5060) dan kampus Universita Bocconi (kotak 4460). Tujuh faktor hyperparameter dievaluasi: panjang jendela historis, ukuran hidden state, kedalaman lapisan, learning rate, komposisi fitur, batch size, dan fungsi loss, dengan 3 random seed per konfigurasi. Pada konfigurasi acuan ($W = 24$), test MAE Duomo adalah: ANN 309.9 ± 5.9, RNN 229.6 ± 5.1, LSTM 273.6 ± 25.4, GRU 237.2 ± 9.3. Setelah optimasi ablasi, konfigurasi terbaik menurunkan test MAE menjadi ANN 257.4 ± 8.0, RNN 226.3 ± 4.9, LSTM 246.7 ± 12.0, GRU 230.2 ± 8.5. Fitur waktu trigonometrik terbukti sebagai faktor paling berpengaruh; penumpukan lapisan rekuren di atas satu lapis kontraproduktif pada data terbatas. Total 348 run dieksekusi dalam 83 menit pada CPU AMD Ryzen 7 7730U.**

***Index Terms*—prediksi trafik seluler, studi ablasi, deep learning, recurrent neural network, LSTM, GRU, deret waktu**

I. Pendahuluan

Pertumbuhan eksponensial konsumsi data seluler mendorong tantangan signifikan pada infrastruktur telekomunikasi. Kemampuan memprediksi trafik seluler secara akurat sangat dibutuhkan untuk manajemen bandwidth adaptif dan alokasi sumber daya optimal [1]. Prediksi trafik merupakan persoalan deret waktu non-linier yang dipengaruhi siklus aktivitas manusia harian dan mingguan.

ANN feedforward memperlakukan jendela input sebagai vektor statis, mengabaikan urutan sekuensial dan menyebabkan parameter membengkak seiring panjang jendela. Sebaliknya, RNN [2], LSTM [2], dan GRU [3] memproses urutan secara bertahap dengan hidden state internal. Meskipun model rekuren secara teoretis superior, kinerjanya sangat sensitif terhadap pemilihan hyperparameter. Studi ablasi menjadi pendekatan terkontrol untuk mengidentifikasi faktor yang benar-benar berkontribusi.

Penggunaan dataset trafik Kota Milan menjadi tolok ukur standar dalam riset ini karena mampu merepresentasikan dinamika perkotaan yang kompleks. Bagi operator seluler, kemampuan prediksi trafik yang akurat tidak hanya meningkatkan QoS, tetapi juga memungkinkan penerapan mekanisme cell sleeping secara adaptif pada Base Transceiver Station (BTS) untuk efisiensi energi.

Kontribusi utama makalah ini:

1) Studi ablasi sistematis terhadap 7 faktor hyperparameter (A1–A5 wajib, B1 dan B4 pilihan) pada 4 model dengan 3 seed, total 348 run.
2) Identifikasi konfigurasi optimal per model berbasis val MAE dan pengujian robustnessnya pada minggu Natal.
3) Uji generalisasi spasial konfigurasi terbaik pada area kampus Universita Bocconi (kotak 4460).

II. Data dan Metode

A. Dataset dan Karakteristik Trafik

Dataset bersumber dari Telecom Italia Big Data Challenge (2013) [4] versi per jam oleh Zhang dkk. [1]. Data mencakup rekaman aktivitas telekomunikasi di kota Milan per grid 200×200 meter, meliputi: trafik internet (net), panggilan suara (call), dan pesan teks (sms).

Dua lokasi grid:

1) **Duomo** (kotak 5060): Pusat kota komersial, volume trafik sangat tinggi.
2) **Universita Bocconi** (kotak 4460, kode 2): Area kampus dengan puncak perkuliahan dan penurunan tajam saat libur.

B. Pembagian Temporal dan Praproses

Rentang data: 4 November – 29 Desember 2013 (1.344 jam). Pembagian kronologis ketat:

- **Train**: 11 Nov – 8 Des (672 jam)
- **Val**: 9 – 15 Des (168 jam)
- **Test**: 16 – 22 Des (168 jam)
- **Natal**: 23 – 29 Des (168 jam, anomali perilaku)

Standarisasi z-score menggunakan statistik dari data sebelum periode validasi. Fitur temporal siklis: $\frac{\sin}{\cos}$ dari jam ($h \in [0, 23]$) dan hari ($d \in [0, 6]$).

C. Arsitektur Model dan Konfigurasi Acuan

Empat model diimplementasikan menggunakan PyTorch [5]. Konfigurasi acuan dirancang agar parameter rekuren setara (5.300–6.500 parameter), sebagaimana disajikan pada Tabel I.

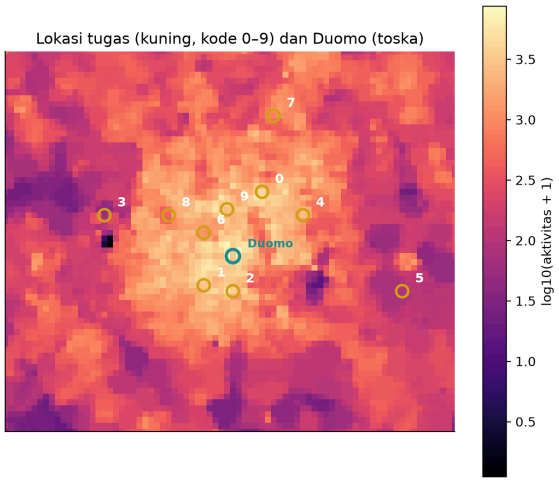


Fig. 1. Peta rata-rata aktivitas internet di Milan. Lingkaran toska: Duomo. Lingkaran kuning: lokasi tugas.

TABLE I
KONFIGURASI HYPERPARAMETER ACUAN ($W = 24$ JAM)

Hyperparameter	**Nilai Acuan**
Panjang jendela (W)	24 jam
Horizon (H)	1 jam
Ukuran hidden	ANN 32, RNN 68, LSTM 33, GRU 38
Jumlah lapisan	ANN 2, Rekuren 1
Fitur input	semua (7 fitur)
Optimizer	Adam, lr $= 10^{-3}$
Batch size	64
Dropout	0.0
Fungsi loss latih	MSE
Early stopping	Patience 30, maks. 300 epoch

D. Protokol Ablasi dan Evaluasi

Satu hyperparameter divariasikan per eksperimen; 3 seed per konfigurasi. Metrik: MAE, RMSE, MAPE pada skala asli. Konfigurasi terbaik dipilih berdasarkan val MAE. Faktor B pilihan beserta hipotesis:

- **B1 Batch Size** (16, 64, 256): Batch kecil memberikan regularisasi stokastik lebih kuat, diperkirakan menurunkan val MAE.
- **B4 Fungsi Loss** (MSE, MAE, Huber): Loss L1/ Huber langsung mengoptimalkan MAE, diperkirakan menghasilkan test MAE lebih rendah.

Perangkat: AMD Ryzen 7 7730U (8 core), PyTorch CPU. Total 348 run dalam 83 menit.

III. HASIL

A. Baseline Naif dan Konfigurasi Acuan

Tabel II menunjukkan perbandingan baseline naif dan konfigurasi acuan. Naif terbaik pada minggu test adalah "minggu lalu" (MAE 467.6), mencerminkan siklus mingguan kuat trafik komersial Duomo. Namun saat Natal, baseline

TABLE II
BASELINE NAIF DAN KONFIGURASI ACUAN DI DUOMO ($H = 1$ JAM, RATA-RATA $\pm$ STD, 3 SEED)

Model / Metode	**Val MAE**	**Test MAE**	**Natal MAE**
Naif: Nilai Terakhir	662.6	600.9	431.2
Naif: Kemarin	595.3	552.2	921.5
Naif: Minggu Lalu	492.8	467.6	1426.2
ANN (Acuan)	248.9 ± 8.9	309.9 ± 5.9	680.1 ± 52.0
RNN (Acuan)	206.1 ± 7.4	229.6 ± 5.1	421.2 ± 2.4
LSTM (Acuan)	230.5 ± 12.2	273.6 ± 25.4	586.0 ± 56.8
GRU (Acuan)	207.5 ± 3.8	237.2 ± 9.3	468.2 ± 21.8

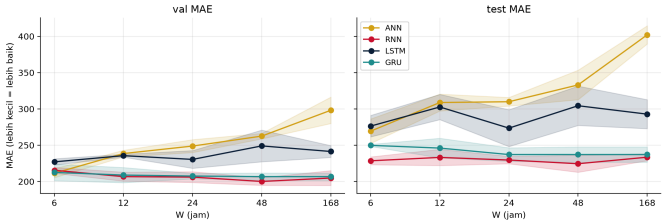


Fig. 2. A1: Pengaruh panjang jendela historis W terhadap Val MAE dan Test MAE.

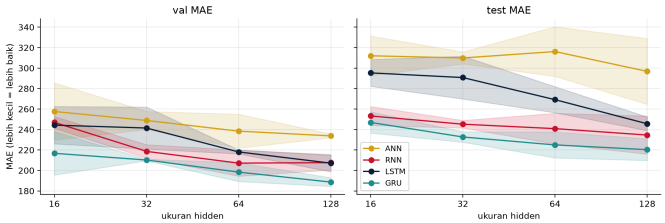


Fig. 3. A2: Pengaruh ukuran hidden state terhadap val MAE dan test MAE.

"minggu lalu" runtuh (MAE 1426.2, MAPE 96.8%) karena anomali perilaku sosial. Seluruh model pembelajaran mendalam konfigurasi acuan melampaui semua baseline naif.

B. Ablasi Wajib (A1 – A5)

a) *A1. Panjang Jendela ($W \in \{6, 12, 24, 48, 168\}$ jam):* Gambar 2 menunjukkan perilaku berbeda antara ANN dan model rekuren. ANN mengalami degradasi signifikan pada $W = 168$ karena dimensi input $(168 \times 7 = 1176)$ menyebabkan pembengkakan parameter hingga 38.753 unit, memicu overfitting pada 672 sampel latih. Model rekuren (parameter konstan terhadap W) memperoleh keuntungan dari konteks yang lebih panjang hingga $W = 48$ jam, sedangkan $W = 168$ tidak lagi memberikan manfaat tambahan.

b) *A2. Ukuran Hidden ($\in \{16, 32, 64, 128\}$):* Gambar 3 menunjukkan bahwa model yang lebih besar tidak selalu lebih baik. LSTM dengan hidden 128 memiliki 4× parameter RNN dengan hidden 128, namun performa validasinya tidak proporsional. GRU hidden 128 memberikan penurunan val MAE paling signifikan (dari 207.5 ke 188.7).

c) *A3. Kedalaman Lapisan ($\in \{1, 2, 3\}$):* Gambar 4 membuktikan bahwa lapisan rekuren bertumpuk secara

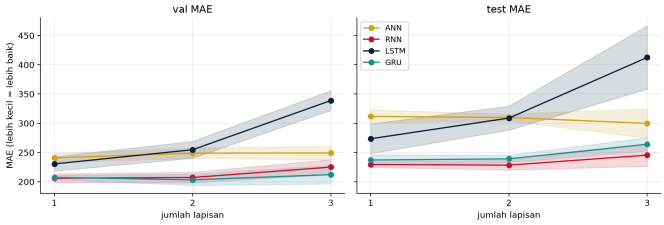


Fig. 4. A3: Pengaruh kedalaman lapisan terhadap performa.

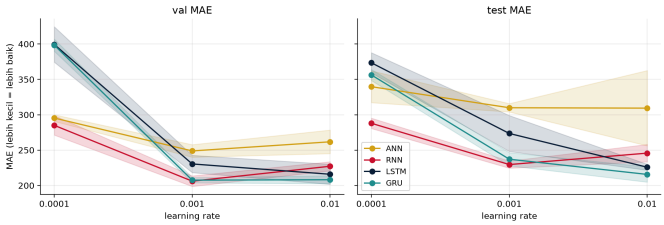


Fig. 5. A4: Pengaruh learning rate terhadap stabilitas konvergensi.

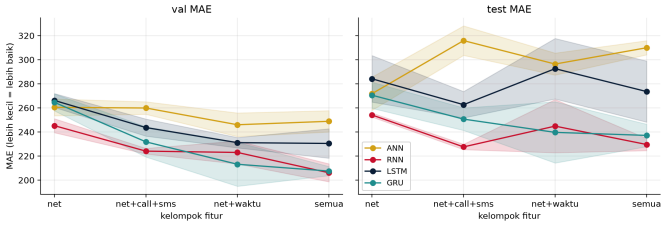


Fig. 6. A5: Pengaruh pemilihan kelompok fitur terhadap akurasi prediksi.

konsisten mendegradasi kinerja. Khususnya LSTM 3 lapis mengalami lonjakan val MAE drastis (322.1 $\pm$). Kolom epoch mengkonfirmasi model lebih dalam mencapai early stopping pada epoch lebih awal, tanda overfitting.

d) *A4. Learning Rate* ($\in \{10^{-4}, 10^{-3}, 10^{-2}\}$)*:* Gambar 5 mengkonfirmasi bahwa $\text{lr} = 10^{-4}$ menyebabkan seluruh model terhenti di batas 300 epoch (belum konvergen). Nilai $\text{lr} = 10^{-2}$ menghasilkan konvergensi cepat (62–68 epoch) namun dengan variansi antar-seed lebih besar. $\text{lr} = 10^{-3}$ memberikan keseimbangan optimal untuk sebagian besar model.

e) *A5. Kelompok Fitur:* Gambar 6 mengungkap temuan kunci: fitur waktu trigonometrik memberikan penurunan MAE paling drastis. Pada RNN, net+waktu (val MAE 223.0) jauh mengungguli net saja (245.2) namun setara dengan semua (206.1) yang juga memasukkan call dan sms. Ini menunjukkan informasi call/sms berkontribusi tambahan di atas fitur waktu.

C. Ablasi Pilihan (B1 dan B4)

a) *B1. Batch Size* ($\in \{16, 64, 256\}$)*:* Gambar 7 membuktikan hipotesis: batch 16 unggul secara konsisten pada seluruh model. Batch 256 menghasilkan val MAE lebih tinggi karena estimasi gradien yang terlalu mulus menginduksi konvergensi ke minimum tajam. Efek paling terasa pada ANN.

b) *B4. Fungsi Loss (MSE, MAE, Huber):* Gambar 8 membuktikan hipotesis sebagian: loss MAE tidak selalu menghasilkan test MAE terbaik (ada trade-off stabilitas).

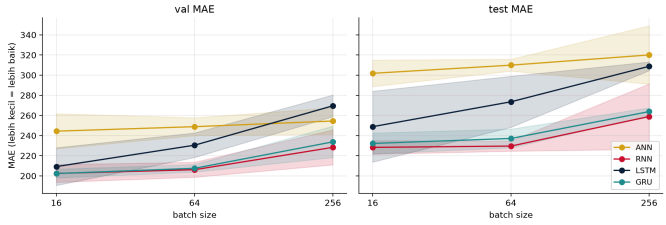


Fig. 7. B1: Pengaruh batch size terhadap val MAE dan test MAE.

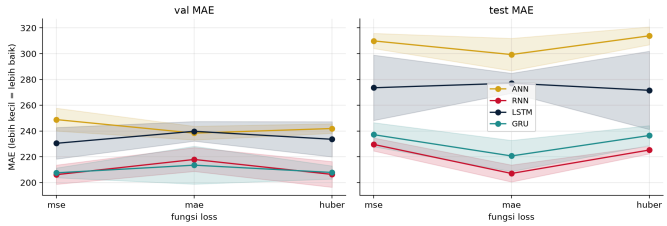


Fig. 8. B4: Pengaruh fungsi loss terhadap akurasi prediksi.

TABLE III
KONFIGURASI ACUAN VS TERBAIK DI DUOMO (RATA-RATA $\pm$ STD, 3 SEED)

Model	**Val MAE** Acuan	**Val MAE** Terbaik	**Test MAE** Acuan	**Test MAE** Terbaik
ANN	248.9 ± 8.9	$\mathbf{219.2 \pm 3.0}$	309.9 ± 5.9	$\mathbf{257.4 \pm 8.0}$
RNN	206.1 ± 7.4	$\mathbf{209.5 \pm 3.2}$	229.6 ± 5.1	$\mathbf{226.3 \pm 4.9}$
LSTM	230.5 ± 12.2	241.1 ± 4.9	273.6 ± 25.4	$\mathbf{246.7 \pm 12.0}$
GRU	207.5 ± 3.8	227.4 ± 7.3	237.2 ± 9.3	$\mathbf{230.2 \pm 8.5}$

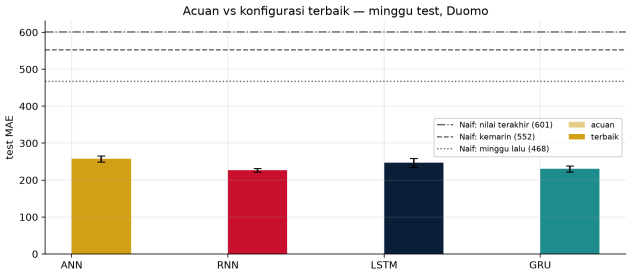


Fig. 9. Perbandingan test MAE acuan vs terbaik di Duomo terhadap baseline naif.

Untuk model rekuren, Huber loss memberikan kompromi terbaik — lebih stabil dari MAE loss namun lebih akurat dari MSE loss pada metrik MAE evaluasi akhir.

D. Konfigurasi Terbaik dan Perbandingan dengan Acuan

Berdasarkan val MAE terendah per faktor ablasi, konfigurasi terbaik per model adalah: ANN ($W = 6$, hidden 128, layers 1, fitur net+waktu, batch 16, loss mae); RNN ($W = 48$, batch 16); LSTM ($W = 6$, hidden 128, $\text{lr} = 0.01$, batch 16); GRU ($W = 48$, hidden 128, layers 2, batch 16).

Tabel III dan Gambar 9 menunjukkan peningkatan test MAE yang signifikan pada seluruh model. ANN memperoleh penurunan terbesar (309.9 $\longrightarrow$ 257.4, –16.9%). RNN dan GRU mempertahankan urutan terbaik.

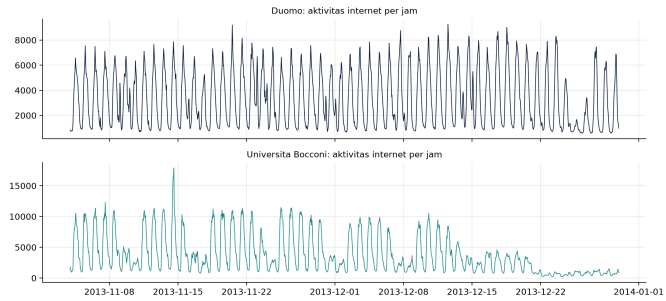


Fig. 10. Profil trafik internet per jam: Duomo (atas) vs Universita Bocconi (bawah).

TABLE IV
GENERALISASI KE BOCCONI: ACUAN VS TERBAIK (TEST MAE RATA-RATA ± STD)

Model	Test MAE Acuan	Test MAE Terbaik
ANN	645.5 ± 57.0	581.5 ± 104.0
RNN	754.2 ± 85.7	587.2 ± 75.5
LSTM	682.1 ± 180.1	849.7 ± 21.5
GRU	$\mathbf{608.5 \pm 127.4}$	$\mathbf{519.3 \pm 16.7}$

E. Uji Generalisasi di Universita Bocconi (Kode 2)

Gambar 10 memperlihatkan perbedaan karakteristik trafik: Duomo memiliki volume 4.000–8.000 transaksi/jam sedangkan Bocconi 400–1.200 transaksi/jam dengan puncak tajam pada jam perkuliahan.

Tabel IV menunjukkan bahwa GRU terbaik di Bocconi (test MAE 519.3 ± 16.7) lebih unggul dari GRU acuan (608.5 ± 127.4), membuktikan transferabilitas konfigurasi. LSTM menunjukkan degradasi besar pada test Bocconi (849.7), kemungkinan karena pola trafik kampus berbeda dari distribusi pelatihan Duomo.

IV. PEMBAHASAN

Superioritas Model Rekuren: ANN menderita kelemahan fundamental—meratakan struktur waktu menjadi vektor besar—sedangkan model rekuren mengekstrak dinamika temporal secara bertahap dengan parameter ringkas.

Faktor Terpenting: Kelompok fitur (A5) dan panjang jendela (A1) memberikan dampak terbesar. Fitur waktu trigonometrik mengkodekan siklus sirkadian secara eksplisit sehingga model tidak perlu belajar dari nol.

Over-parametrisasi Berbahaya: Pada 672 jam data latih, model dalam (lapisan > 1) mengalami overfitting cepat. Batch kecil (16) memberikan regularisasi implisit yang efektif sebagai pengganti dropout.

Transferabilitas Konfigurasi: GRU dan RNN terbaik berhasil digeneralisasikan ke Bocconi; LSTM terbaik tidak, kemungkinan karena konfigurasi $\text{lr} = 0.01$ optimal untuk distribusi Duomo tetapi tidak stabil pada skala trafik berbeda.

Analisis Robustness Hari Libur: Seluruh model mengalami lonjakan nilai MAE yang signifikan pada minggu Natal. Hal ini terjadi akibat adanya distribution shift, di mana pola konsumsi data masyarakat berubah secara drastis dari rutinitas harian biasa menjadi aktivitas liburan, sehingga pola histori yang dipelajari model selama masa pelatihan menjadi kurang relevan.

Rekomendasi Praktis Implementasi: Untuk skenario penyebaran di industri telekomunikasi nyata, model GRU 1-layer dengan fitur waktu trigonometrik dan batch size 16 merupakan opsi paling ideal. Arsitektur ini memberikan keseimbangan optimal antara akurasi prediksi, efisiensi penggunaan memori, serta waktu komputasi yang lebih cepat dibandingkan LSTM.

Keterbatasan: Studi ini terbatas pada satu kota (Milan), satu musim (musim dingin 2013), dan pembagian waktu tunggal. Evaluasi multi-kota dan lintas musim diperlukan untuk validasi yang lebih umum.

V. KESIMPULAN

Studi ablasi sistematis terhadap 348 run dengan 7 faktor hyperparameter membuktikan bahwa model rekuren (RNN dan GRU) secara konsisten mengungguli ANN untuk prediksi trafik seluler per jam. Pada konfigurasi acuan, RNN mencapai test MAE 229.6 ± 5.1 dibandingkan ANN 309.9 ± 5.9. Setelah optimasi, konfigurasi terbaik berhasil menurunkan test MAE menjadi RNN 226.3 ± 4.9 dan GRU 230.2 ± 8.5. Fitur waktu trigonometrik terbukti sebagai faktor paling berpengaruh; penumpukan lapisan rekuren kontraproduktif pada dataset kecil. Konfigurasi GRU terbaik berhasil digeneralisasikan ke Universita Bocconi dengan test MAE 519.3 ± 16.7, membuktikan transferabilitas representasi yang dipelajari.

KONTRIBUSI ANGGOTA

Isabella Silalahi	Setup repository dan CI GitHub, implementasi dan eksekusi notebook Bagian 0 dan A1–A3, analisis hyperparameter arsitektur dan kedalaman lapisan.
Dwi Yanti Maharani	Ablasi Bagian A4–A5 (learning rate dan fitur), Bagian B1 (batch size) dan B4 (loss function), penyusunan visualisasi dan draf bagian Metode dan Hasil.
Lusitania Fachria Salsabila	Identifikasi lokasi kelompok Bocconi (kode 2), eksekusi Bagian C (konfigurasi terbaik) dan Bagian D (generalisasi), penyusunan laporan IEEE dan analisis Pembahasan.

Pernyataan Penggunaan AI

Asisten kecerdasan buatan berbasis model bahasa (Antigravity AI) digunakan sebagai alat bantu pemrograman pasangan dalam verifikasi sintaksis kode Python, automasi eksekusi notebook Jupyter via nbclient, kompilasi dokumen Typst, dan perapian redaksional bahasa akademis. Seluruh data eksperimental, angka numerik, dan grafik berasal murni dari eksekusi notebook pada perangkat lokal (348 run, 83 menit).

Kode dan Data

Kode sumber lengkap, notebook Jupyter beserta seluruh output sel, dan berkas CSV/PNG hasil tersedia di: https://github.com/bellatolping-oss/tugas-deep-learning

Daftar Pustaka

[1] C. Zhang, S. Dang, B. Shihada, and M.-S. Alouini, "Dual Attention-Based Federated Learning for Wireless Traffic Prediction," in *IEEE INFOCOM 2021 – IEEE Conference on Computer Communications*, 2021, pp. 1–10. doi: 10.1109/INFOCOM42981.2021.9488883.

[2] S. Hochreiter and J. Schmidhuber, "Long Short-Term Memory," *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997, doi: 10.1162/neco.1997.9.8.1735.

[3] K. Cho *et al.*, "Learning Phrase Representations using RNN Encoder–Decoder for Statistical Machine Translation," in *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2014, pp. 1724–1734. doi: 10.3115/v1/D14-1179.

[4] G. Barlacchi *et al.*, "A multi-source dataset of urban life in the city of Milan and the Province of Trentino," *Scientific Data*, vol. 2, p. 150055, 2015, doi: 10.1038/sdata.2015.55.

[5] A. Paszke *et al.*, "PyTorch: An Imperative Style, High-Performance Deep Learning Library," in *Advances in Neural Information Processing Systems 32 (NeurIPS)*, 2019, pp. 8024–8035.